

Sistema de Reconocimiento de Actividad Humana mediante Visión por Computador y Machine Learning

¹De La Cruz Mariana - A00399618, ²Gómez Valentina - A00398790, ³Delgado Alexis - A00399176, ⁴Amorocho Juan Camilo - A00399789

^{1,2,3,4}Ingeniería de Sistemas

^{1,2,3,4} Universidad Icesi, Facultad de Ingeniería, Diseño y Ciencias Aplicadas

Algoritmos y Programación III

Santiago de Cali, 22 de noviembre de 2025

Resumen (Abstract)

Este documento presenta un sistema integral para el reconocimiento automatizado de actividades humanas utilizando técnicas de visión por computador y aprendizaje automático (Machine Learning). El sistema emplea MediaPipe Pose para extraer 33 puntos de referencia corporales de secuencias de video, calculando 12 características biomecánicas que incluyen ángulos articulares, velocidad, aceleración y simetría corporal. Se entrenaron tres modelos supervisados (Random Forest, SVM con kernel RBF y XGBoost) sobre un conjunto de datos de 86 videos distribuidos en 8 categorías de actividad. Se aplicó Análisis de Componentes Principales (PCA) para reducir la dimensionalidad de 12 a 6 características, preservando el 91.73% de la varianza. Los mejores modelos lograron una exactitud del 94.44% en el conjunto de prueba. Este trabajo demuestra la viabilidad del análisis de movimiento automatizado para aplicaciones en salud y deportes, abordando explícitamente consideraciones éticas sobre privacidad y despliegue responsable.

Palabras clave: Reconocimiento de Actividad Humana (HAR), Visión por Computador, MediaPipe, Machine Learning, PCA, Análisis Biomecánico.

1. Introducción

1.1 Contexto y Motivación

El reconocimiento de actividades humanas (HAR) es crucial en la intersección de la visión por computador y la biomecánica. La capacidad de clasificar movimientos tiene implicaciones profundas en la salud (rehabilitación, detección de caídas) y el deporte. Tradicionalmente, este análisis es manual y subjetivo; sin embargo, herramientas como MediaPipe permiten ahora una extracción automatizada y objetiva de información esquelética.

1.2 Planteamiento del Problema e Ingeniería Compleja

El desarrollo de este sistema constituye un problema complejo de ingeniería (Competencia P13) debido a:

- 1. Alta dimensionalidad y no linealidad:** Mapear secuencias de video a vectores de características implica agregación temporal y cálculos geométricos complejos.
- 2. Variabilidad:** Las actividades humanas poseen alta variabilidad entre sujetos y entornos.
- 3. Restricciones de tiempo real:** La inferencia debe ser inmediata para aplicaciones de monitoreo.
- 4. Limitación de datos:** La necesidad de generalizar modelos con un conjunto de datos pequeño ($n=86$) requiere estrategias matemáticas robustas como la reducción de dimensionalidad.



1.3 Objetivos

El objetivo general es desarrollar un sistema inteligente capaz de clasificar actividades (caminar, sentarse, sentadillas, movimientos de cadera) usando video RGB. Los objetivos específicos incluyen la recolección de datos, ingeniería de características biomecánicas, evaluación de modelos supervisados y un análisis ético-social exhaustivo.

2. Marco Teórico y Formulación Matemática

2.1 Estimación de Pose y MediaPipe

Se utiliza MediaPipe Pose para detectar 33 puntos de referencia (x, y, z) en el espacio 3D.



Extracción de landmarks corporales utilizando MediaPipe en el conjunto de datos propio.

2.2 Ingeniería de Características y Fundamentación Matemática

Para transformar los datos crudos en información útil para el clasificador, se formularon matemáticamente las siguientes características:

1. Cálculo de Ángulos Articulares:

El ángulo θ formado por tres puntos (a, b, c) donde b es el vértice, se calcula mediante el producto punto, asegurando estabilidad numérica:

$$\theta = \arccos \left(\frac{ba \cdot bc}{|ba| \cdot |bc|} \right) \quad (1)$$

Justificación: Los ángulos son invariantes a la posición de la cámara y al tamaño del sujeto, lo que mejora la generalización.

2. Velocidad y Aceleración: Dada la posición de la cadera p_t en el tiempo t :

$$v_t = \frac{\|p_t - p_{t-1}\|}{\Delta t}, a_t = \frac{v_t - v_{t-1}}{\Delta t} \quad (2)$$

Donde $\Delta t = 1/30$ segundos. Estas derivadas capturan la dinámica temporal del movimiento.

2.3 Análisis de Componentes Principales (PCA)

Para mitigar el sobreajuste (overfitting), se buscó una proyección ortogonal $w \in R^{12 \times 6}$ que maximice la varianza:

$$\max_W \text{tr}(W^T \Sigma W) \quad \text{sujeto a} \quad W^T W = I \quad (3)$$

Donde Σ es la matriz de covarianza de las características normalizadas.

3. Metodología

Se siguió la metodología **CRISP-DM**, adaptada para visión por computador.



Metodología CRISP-DM.

3.1 Preparación de Datos

- **Recolección:** 86 videos (aprox. 3.1 seg cada uno) en 8 categorías: Adelante, Atrás, Sentado, Cadera_Alfrente, Caderas, Lado, Sentadilla, Tijeras.
- **Preprocesamiento:**
 1. Limpieza de frames con baja confianza.
 2. **Normalización MinMax:** Escalamiento al rango $[0, 1]$ para asegurar que características de distancia no dominen sobre las angulares (crucial para SVM).
 3. **Filtrado de Outliers:** Uso de rango intercuartil (IQR).


3.2 Modelado

Se evaluaron tres enfoques:

1. **Random Forest:** Ensemble de árboles de decisión (robusto a ruido).
2. **SVM (RBF):** Maximización de margen en espacio transformado no linealmente (ideal para datasets pequeños).
3. **XGBoost:** Boosting de gradiente (alta potencia predictiva).

4. Resultados y Análisis (Competencia P13)


4.1 Análisis de Características y Reducción de Dimensionalidad



Importancia de características. Se observa que los ángulos de cadera y rodilla son los predictores más fuertes.

El análisis de PCA reveló que 6 componentes principales capturan el **91.73%** de la varianza total.

- **PC1 (37.08%):** Correlacionado con características angulares (postura estática).
- **PC2 (24.71%):** Características temporales y brillo.



Proyección de los datos en 2D usando PCA. Se observa una clara separación entre actividades estáticas (Sentado) y dinámicas, aunque existe solapamiento en movimientos de marcha.


4.2 Evaluación de Modelos

Comparativa de rendimiento (Accuracy) entre características originales (12) y reducidas por PCA (6):

Modelo	Original (12 feat.)	PCA (6 PC)	Cambio	Análisis Matemático
Random Forest	100.0%	94.44%	-5.56%	Reducción de overfitting; el 100% inicial era espurio.
SVM (RBF)	100.0%	94.44%	-5.56%	Mantiene alto rendimiento gracias a la maximización del margen.
XGBoost	88.9%	77.78%	-11.12%	Sensible a la pérdida de interacciones originales entre features.

Tabla 1. Modelos y comparación de rendimiento

4.3 Análisis de Errores



Interpretación: El descenso del 100% al 94.44% al usar PCA es un resultado positivo desde la teoría del aprendizaje estadístico, ya que indica una **mejor generalización** y una reducción de la varianza del modelo (menos "memorización" del ruido de entrenamiento).

5. Análisis de Impactos (Competencia P12)

A continuación, se presenta el análisis de los impactos de la solución propuesta en diferentes dimensiones.

Dimensión	Impactos Positivos (Beneficios)	Impactos Negativos (Riesgos)	Estrategia de Mitigación
Social	Democratización de la salud: Permite rehabilitación remota y objetiva sin visitas clínicas constantes.	Privacidad: Riesgo de identificación biométrica a través de patrones de marcha.	Procesamiento local de datos o anonimización de video (solo guardar coordenadas).
Económica	Reducción de costos: Ahorro estimado de \$50-100 USD por sesión de terapia evitada.	Desplazamiento laboral: Automatización parcial de tareas de diagnóstico visual.	Posicionar la herramienta como soporte de decisión, no reemplazo del experto.
Ambiental	Huella de carbono: Reduce emisiones por transporte de pacientes (aprox. 200 kg CO_2 /año/paciente).	Consumo energético: Entrenamiento de modelos y servidores en la nube.	Uso de modelos eficientes (PCA) y proveedores cloud con energía renovable.
Global	Accesibilidad: Solución viable en países en desarrollo al requerir solo un smartphone estándar.	Sesgo cultural: Modelos entrenados en Colombia pueden no generalizar a normas de movimiento de otras culturas.	Recolección de datasets diversos y auditorías de equidad antes del despliegue global.

Tabla 2. Análisis de impactos

5.2 Justificación

El impacto ambiental positivo (reducción de viajes) supera significativamente el costo computacional de inferencia, el cual es mínimo (0.000012 kg CO_2 por video). Socialmente, la herramienta atiende la escasez de especialistas en zonas rurales.

6. Consideraciones Éticas y Responsabilidad Profesional (Competencia P11)

Este proyecto se adhiere al Código de Ética de IEEE y a principios de responsabilidad profesional.

Dilema Ético	Principio Relacionado	Decisión/Medida Adoptada
Privacidad de Datos	Respeto a la privacidad y confidencialidad.	Minimización de Datos: El sistema no almacena los videos crudos tras el procesamiento; solo se guardan vectores numéricos de características.
Consentimiento	Autonomía y transparencia.	Protocolo Informado: Todos los participantes firmaron un consentimiento explícito sobre el uso académico de sus datos biométricos.
Sesgo Algorítmico	Justicia y no discriminación.	Documentación de Limitaciones: Se declara explícitamente que el dataset carece de diversidad etaria y de movilidad reducida, advirtiendo contra el uso médico no validado.
Vigilancia Masiva	Bienestar público y evitar daños.	Restricción Funcional: La herramienta requiere carga manual de video y no soporta vigilancia continua en tiempo real sin interacción del usuario.

Tabla 3. Consideraciones éticas

6.2 Reflexión

Como ingenieros, reconocemos que la tecnología es dual. Aunque diseñada para la salud, el análisis de marcha puede usarse para vigilancia. Por ello, documentamos las limitaciones y diseñamos el software para prevenir su uso como herramienta de monitoreo encubierto.

7. Conclusiones y Trabajo Futuro

7.1 Conclusiones Técnicas

1. **Efectividad de PCA:** La reducción a 6 componentes principales demostró ser una estrategia matemática efectiva para controlar el sobreajuste en datasets pequeños, alineándose con el principio de parsimonia.
2. **Robustez de Modelos:** SVM con kernel RBF y Random Forest demostraron el mejor desempeño (94.44%), validando el uso de características biomecánicas diseñadas manualmente sobre el uso de coordenadas crudas.
3. **Ingeniería:** Se logró una solución de bajo costo computacional apta para despliegue web, cumpliendo el objetivo de accesibilidad.

7.2 Trabajo Futuro

- **Expansión del Dataset:** Incluir sujetos con patologías reales de movimiento.
- **Modelado Temporal:** Implementar redes LSTM para capturar secuencias complejas mejor que el promedio temporal actual.
- **Validación Clínica:** Comparar las métricas del sistema con equipos de captura de movimiento de grado médico (Vicon).

8. Referencias Bibliográficas

- [1] C. Lugaresi et al., "MediaPipe: A Framework for Building Perception Pipelines," *arXiv:1906.08172*, 2019. <https://arxiv.org/abs/1906.08172>
- [2] I. T. Jolliffe y J. Cadima, "Principal Component Analysis: A Review," *Phil. Trans. R. Soc. A*, 2016. <https://royalsocietypublishing.org/doi/10.1098/rsta.2015.0202>

[3] IEEE, "IEEE Code of Ethics," 2020.
<https://www.ieee.org/about/corporate/governance/p7-8.html>

Enlace al video

https://youtu.be/vb6bch6_SzU